

Домашнее задание по теме «Метагеномика»

Выполнила:

Кукушкина Ирина Романовна

Группа: 1

Данные: Dat2

Param: Param2

Часть 1. Определение таксономических единиц, их встречаемости и таксономии в образцах.

Задание 1.

0.5 балла. Приложить к отчету таблицу со статистикой по образцам.

	input	filtered	denosiseF	denosiseR	merged	nochim
25.R1.fastq	15997	12609	11940	12336	10149	9319
26.R1.fastq	14480	11335	10624	11031	8782	8374
27.R1.fastq	17476	13894	13244	13562	10882	10137
28.R1.fastq	18949	14755	13899	14359	11401	10637
29.R1.fastq	16467	13086	12435	12750	10700	10062
30.R1.fastq	17049	13530	12692	13165	10626	10127
31.R1.fastq	16948	13314	12602	12909	10402	9633
32.R1.fastq	15448	12174	11551	11787	9473	8687
33.R1.fastq	15385	12198	11467	11858	9632	8983
34.R1.fastq	16621	13305	12568	12889	10435	9670
35.R1.fastq	16629	13162	12382	12756	10484	9885
36.R1.fastq	17187	13692	13001	13282	10967	10189
37.R1.fastq	16566	13106	12349	12776	10255	9557
38.R1.fastq	17618	14002	13222	13518	10834	9828

0.5 балл. Описать, сколько % отсеялось на каждом этапе.

	input	filtered	denoisedF	denoisedR	merged	nochim
Было до (среднее)	16630	16630	13154	13154	12604	10358
Стало (среднее)	-	13154	12425	12784	10358	9649
Отсеялось относительно прошлого этапа (%)	-	20%	5,5%	2,8%	21%	6,8%

Всего отсеялось: $(1 - 9649/16630) * 100 = 42\%$

0.5 балл. Объяснить почему отсеялось много/мало?

На этапе фильтрации отсеялось 20%, это оптимальное значение. Принято, что после этого этапа должно остаться не меньше 80% чтений. Сохранить большее количество чтений не получилось из-за подрезки образцов, подбирались такая длина чтений, чтобы качество на концах не портилось.

Далее denoisedF и denoisedR. Алгоритм определил, какие варианты последовательностей, скорее всего, являются результатом ошибок

секвенирования. В результате отсеялся небольшой % чтений (5,5% и 2,8%), так как ошибки секвенирования не часты.

На этапе объединения отсеялось 21%. Не все парные прочтения могут быть успешно объединены, так как между парными ридами может быть слишком малая область перекрытия (тем более что в основном были чтения длиной 134-139).

Химеры – артефакты пцр, при качественном секвенировании их количество обычно не велико. На этапе удаления химер отсеялось 6,8%.

0.5 балла. Дайте биологическую/техническую интерпретацию.

Всего было отсеяно 42%, что является нормой. При этом обнаружено 2155 уникальных ASV, большинство из них имеет длину 251, что соответствует ожидаемой длине целевого фрагмента после объединения парных чтений.

0.25 балла. Сколько в итоговой таблице получилось прочтений на образец.

Информация о количестве прочтений на образец, оставшихся после всех вышеперечисленных этапов, находится в столбце nochim. В среднем на образец приходится 9649 прочтений.

0.25 балла. Сколько получилось ASV в среднем в образцах.

Нужно разделить общее количество ASV в таблице на количество образцов и учесть, что не все ASV присутствуют во всех образцах.

```
{r}
print(mean(rowSums(seqtab.nochim > 0)))

[1] 403.7143
```

Задание 2.

0.5 балла. Приведите в отчетном документе скриншот полученной таксономии.

ASV <chr>	Kingdom <chr>	Phylum <chr>	Class <chr>	Order <chr>	Family <chr>	Genus <chr>
TACAGAGGCC...	Bacteria	Verrucomicrobiota	Kiritimatiellae	WCHB1-41	NA	NA
TACAGAGGCC...	Bacteria	Verrucomicrobiota	Kiritimatiellae	WCHB1-41	NA	NA
TACATAGGTT...	Bacteria	Firmicutes	Bacilli	Mycoplasmatales	Mycoplasmataceae	Mycoplasma
TACAGAGGCC...	Bacteria	Verrucomicrobiota	Kiritimatiellae	WCHB1-41	NA	NA
TACAGAGGCC...	Bacteria	Verrucomicrobiota	Kiritimatiellae	WCHB1-41	NA	NA
TACAGAGGCC...	Bacteria	Verrucomicrobiota	Kiritimatiellae	WCHB1-41	NA	NA
TACGTAGGTG...	Bacteria	Firmicutes	Bacilli	Erysipelotrichales	Erysipelatoclostridiaceae	UCG-004
TACGTAGGTG...	Bacteria	Firmicutes	Bacilli	Erysipelotrichales	Erysipelatoclostridiaceae	UCG-004
TACAGAGGCC...	Bacteria	Verrucomicrobiota	Kiritimatiellae	WCHB1-41	NA	NA
TACGTAGGTG...	Bacteria	Firmicutes	Bacilli	Erysipelotrichales	Erysipelatoclostridiaceae	UCG-004
TACGGAGGAT...	Bacteria	Bacteroidota	Bacteroidia	Bacteroidales	Bacteroidales RF16 group	NA
TACATAGGTT...	Bacteria	Firmicutes	Bacilli	Mycoplasmatales	Mycoplasmataceae	Mycoplasma
TACGGAGGAT...	Bacteria	Bacteroidota	Bacteroidia	Bacteroidales	Bacteroidales RF16 group	NA
TACGTAGGTG...	Bacteria	Firmicutes	Bacilli	Erysipelotrichales	Erysipelatoclostridiaceae	UCG-004
TACAGAGGCC...	Bacteria	Verrucomicrobiota	Kiritimatiellae	WCHB1-41	NA	NA
TACGGAGGAT...	Bacteria	Bacteroidota	Bacteroidia	Bacteroidales	Paludibacteraceae	NA
TACAGAGGTG...	Bacteria	Verrucomicrobiota	Kiritimatiellae	WCHB1-41	NA	NA

0.5 балла. Сколько есть unclussify родов в данных?

```
##{r}
#unclussify родов в данных
sum(is.na(df_taxa$Genus)) #количество NA
nrow(df_taxa) #всего строк
mean(is.na(df_taxa$Genus)) * 100 #процент
```

```
[1] 1204
[1] 2155
[1] 55.87007
```

1204 unclussify родов (55,8%)

0.5 балла. Как вы думаете, почему есть неклассифицированные до уровня рода последовательности?

Из-за ограниченности референсных баз: многие микроорганизмы еще не описаны, многие даже не отсекувенированы. Также возможная причина – короткая длина для классификации на уровне рода.

Задание 3.

1 балл. Определите, из какой среды были взяты ваши образцы. Для это необходимо взять таксономическое название видов, определившихся в вашем образце и погуглить.

Определение среды

```
##{r}
head(sort(table(df_taxa$Genus, useNA = "always"), decreasing = TRUE),15)
```

<NA>	Rikenellaceae RC9 gut group	UCG-004
1204	184	84
NK4A214 group	Christensenellaceae R-7 group	Ruminococcus
41	37	32
Treponema	Anaerovorax	Mycoplasma
26	21	21
SP3-e08	UCG-005	Fibrobacter
21	18	17
Lachnospiraceae ND3007 group	Phascolarctobacterium	UCG-002
16	15	14

Fibrobacter – в рубце жвачных животных

Rikenellaceae RC9 gut group – в кишечнике животных, в том числе коз и лошадей

Christensenellaceae R-7 – одно из доминирующих родов в образцах рубца

NK4A214 – бактерия рубца

Таким образом, образцы, скорее всего, взяты из желудка (рубца) жвачного животного (например, коза/лошадь/корова)

Задание 4.

1 балл. К отчету приложите скриншот полученного объекта, сохраненный rds объект. (хотя написано, что задание 1,5 балла)

```
```{r}
print(phy)
print("----")
readRDS("hw_dat_raw.RDS")
```
```

```
phyloseq-class experiment-level object
otu_table() OTU Table: [ 2155 taxa and 14 samples ]
sample_data() Sample Data: [ 14 samples by 2 sample variables ]
tax_table() Taxonomy Table: [ 2155 taxa by 6 taxonomic ranks ]
[1] "----"
phyloseq-class experiment-level object
otu_table() OTU Table: [ 2155 taxa and 14 samples ]
sample_data() Sample Data: [ 14 samples by 2 sample variables ]
tax_table() Taxonomy Table: [ 2155 taxa by 6 taxonomic ranks ]
```

Часть 2. Анализ полученных данных. Анализ представленности таксонов в образцах. Альфа-разнообразие. Бета-разнообразие.

Задание 1.

0.5 балла. В отчете предоставьте скриншот phyloseq объекта. Должно быть видно, сколько было родов до фильтрации и сколько стало после.


```
```{r}
#результаты фильтрации
print(phy)
print("----")
print(fin.phy)
```
```

```
phyloseq-class experiment-level object
otu_table() OTU Table: [ 2155 taxa and 14 samples ]
sample_data() Sample Data: [ 14 samples by 2 sample variables ]
tax_table() Taxonomy Table: [ 2155 taxa by 6 taxonomic ranks ]
[1] "----"
phyloseq-class experiment-level object
otu_table() OTU Table: [ 56 taxa and 14 samples ]
sample_data() Sample Data: [ 14 samples by 2 sample variables ]
tax_table() Taxonomy Table: [ 56 taxa by 6 taxonomic ranks ]
```

Задание 2.

1 балл. В отчете должны быть представлены 2 рисунка с численностями, подпись к ним по типу “Рисунок N. Относительная численность родов из биотопа ...”, а также описание в тексте. Каждый рисунок с описанием к нему - 0.5 баллов.

Рисунок 1. Относительная численность родов в образцах.



Rikenellaceae RC9 gut group – самый обильный род, присутствует во всех образцах с высокой численностью. Это типичный представитель пищеварительного тракта жвачных животных. Rikenellaceae RC9 gut group был обнаружен у разных видов травоядных животных, в том числе у лошадей. Считается, что количество бактерий Rikenellaceae RC9 gut group увеличивается у лошадей, которые переходят с пастбищного на сеновое питание.


Также в образцах обильно представлены UCG-004 и Mycoplasma.

Образцы 33 и 29 выделяются высоким содержанием Mycoplasma и низким содержанием Rikenellaceae RC9 gut group. Образец 25 является единственным, у которого отсутствует Mycoplasma, а Fibrobacter и Monoglobus представлены обильнее чем в остальных образцах.

Согласно исследованиям:

- Низкое содержание Rikenellaceae RC9 gut group и высокое содержание Mycoplasma у лошади может указывать на нарушения в микрофлоре кишечника или инфекционные заболевания, связанные с микоплазмозом или дисбиозом.
- Низкое содержание Rikenellaceae RC9 у жвачных может указывать на дисбиоз, нарушение пищеварения и общее неблагополучие в организме.

Рисунок 2. Тепловая карта clr-трансформированных данных.



Роды с высокой вариабельностью:

- *Mycoplasma*: сильнейшие колебания (ярко видно на примере образцов 25 и 29)
- *Escherichia-Shigella*
- *Methanocorpusculum*
- *Fibrobacter*
- *Lachnospiraceae.ND3007.group*

Среди образцов выделяются:


- Образец 25: резко отрицательное значение у *Mycoplasma* и положительными *Fibrobacter*, *Treponema*, *Methanocorpusculum*
- Образец 29: высокие значения *Mycoplasma* и *Escherichia-Shigella*
- Образец 38: низкий *Bacteroides*

Если сравнивать по Group (Param), то невидно четкого разделения по обилию родов бактерий. Например, образцы 28, 37, 36 (Variable1) имеют высокие значения *Streptococcus*, *Phoenicibacter*, *Bifidobacterium*, *Gilliamella*, в то время как у образцов с Variable2 значения в целом ниже, однако в то же время образцы 26 и 30 (Variable1) имеют низкие значения по этим родам, а 25 и 34 (Variable1) – средние. В целом, если посмотреть на график (линии кластеризации по образцам), то не видно кластеризации по Param2.

Задание 3.

0.5 балла. В отчете должен быть приведен рисунок с альфа-разнообразием, подпись к нему по типу “Рисунок N. Альфа-разнообразие по коэффициентам __ и __, в связи с параметром ...”.

Рисунок 3. Альфа-разнообразие по коэффициентам Observed, Shannon, Simpson, Invsimpson в связи с параметром Param2.



0.5 балла. Должно быть приведено описание графика в тексте и описаны результаты статистического теста.

Параметр Param2 влияет на альфа-разнообразие: у Variable1 наблюдаются более высокие значения по метрикам. Однако различия в метриках небольшие, на уровне нескольких десятых и сотых.

Согласно результатам статистического теста, образцы статистически значимо различаются по параметру Param2 в отношении альфа-разнообразия:

Тест Уилкоксона для observed

W = 29.5 p_value = 0.5640111 Significant = No

Тест Уилкоксона для shanW = 44 p_value = 0.01107226 Significant = Yes

Тест Уилкоксона для simpW = 46 p_value = 0.004079254 Significant = Yes

Тест Уилкоксона для invsimpW = 46 p_value = 0.004079254 Significant = Yes


Средние значения индексов по группам

| Param2 | observed | shan | simp | invsimp |
|------------------|----------|------------|-------------|------------|
| [1,] "Variable1" | "48" | "2.861699" | "0.8915607" | "9.280763" |
| [2,] "Variable2" | "47" | "2.691737" | "0.8686767" | "7.667405" |

Задание 4.

0.5 балла. В отчете должен быть представлен 1 график.

Рисунок 4. Тепловая карта расстояний Брея-Кёртиса.



Статистические тесты

```
## {r}
```

```
#Статистические тесты
```

```
permutest(betadisper(distance,meta$Param2))
```

```
adonis2(distance~Param2, meta)
```

Permutation test for homogeneity of multivariate dispersions

Permutation: free

Number of permutations: 999

Response: Distances

| | Df | Sum Sq | Mean Sq | F | N.Perm | Pr(>F) |
|-----------|----|----------|-----------|--------|--------|--------|
| Groups | 1 | 0.000018 | 0.0000184 | 0.0034 | 999 | 0.931 |
| Residuals | 12 | 0.064534 | 0.0053779 | | | |

Permutation test for adonis under reduced model


Permutation: free

Number of permutations: 999

```
adonis2(formula = distance ~ Param2, data = meta)
```

| | Df | SumOfSqs | R2 | F | Pr(>F) |
|----------|----|----------|---------|--------|--------|
| Model | 1 | 0.03506 | 0.06862 | 0.8841 | 0.475 |
| Residual | 12 | 0.47591 | 0.93138 | | |
| Total | 13 | 0.51097 | 1.00000 | | |

Рисунок 5. RCoA на основе расстояния Брея-Кёртиса.



0.5 балла. К графику должна быть приведена подпись с объяснением, что было посчитано.

Тепловая карта расстояний Брея-Кёртиса:

- Наиболее похожие образцы: 27 и 31, 26 и 36, 27 и 38.
- Образец 25 отличается от большинства других.

На данном графике можно увидеть связь образцов по Param2, если исключить выбивающиеся из общей картины образцы.

РСоА на основе расстояния Брея-Кёртиса:

На графике РСоА группы по Param2 не выглядят четко обособленными, достаточное количество точек находится за пределами эллипсов, что говорит об отсутствии связи по Param2.

Статистические тесты:

betadisper: $F = 0,0034$, $p\text{-value} = 0,931$, где F показывает соотношение межгрупповой и внутригрупповой вариации, чем ближе к нулю, тем меньше различий между группами по разбросу, $p\text{-value}$ – это вероятность ошибиться, если сказать, что группы различаются. То есть разброс внутри групп не различается, вариабельность микробных сообществ внутри групп одинаковая.

adonis2: $R^2 = 0,0686$ (только 6,9% вариации объясняется Param2), $p\text{-value} = 0,475$. Различия между группами статистически не значимы.

Задание 5.

1 балла. Краткое резюме. Отличаются ли образцы по выбранному вами параметру?

Альфа-разнообразие различается по параметру Param2. В группе Variable1 индексы Шеннона, Симпсона и обратный Симпсон выше. Бета-разнообразие не различается между группами. Статистические тесты показывают, что Param2 объясняет только 6,9% вариации, и это влияние не значимо, и на РСоА группы не выглядят обособленными.

Таким образом, параметр Param2 влияет на равномерность, но не влияет на общий состав. Набор родов в обеих группах примерно одинаков, но по-разному распределен. Образцы по параметру Param2 отличаются.